

Université Abdelmalek Essaadi
École Nationale des Sciences Appliquées - Tétouan

Cycle Ingénieur - Génie Informatique (GI1)
Année Universitaire : 2025/2026

Projet Théorie des Langages

Réalisé par :

Bouarguan ABDELLAH
Ben Yacoub NIZAR
El Ghazouani MAROUANE
Cherradi ILYASS
El Younoussi NAFISA

Encadré par :

Pr. AL ACHHAB MOHAMMED

Période de réalisation : 23 Février 2026 - 8 Mars 2026

Sommaire

1	Introduction Générale	4
2	Introduction de la Phase 1	5
3	Recherche Préliminaire, Outils et Étude de Projets Existants	5
3.1	Concepts Théoriques	5
3.2	Format DOT et Écosystème Graphviz	5
3.3	Manipulation Visuelle	6
3.4	Inspiration et Étude de Projets Existants	6
4	Environnement de Travail et Choix Techniques	6
4.1	Le Langage C	6
4.2	Git et Collaboration sur GitHub	6
4.3	Standardisation de la Compilation avec CMake	6
5	Organisation et Répartition du Travail	8
6	Conception et Implémentation de la Phase 1	8
6.1	Structures de données (Question 1 : <code>automate.h</code>)	8
6.2	Lecture et stockage (Question 2 : Parsing dans <code>parser.c</code>)	9
6.3	Moteur d’affichage (Question 3 : <code>display.c</code>)	12
6.4	Interface interactive (Question 4 : <code>main.c</code>)	13
7	Difficultés Rencontrées et Solutions	13
8	Conclusion de la Phase 1	13
9	Introduction de la Phase 2	14
10	Répartition du Travail	14
11	Conception et Implémentation	14
11.1	Génération d’un fichier DOT (Question 5)	14
11.2	Statistiques sur les transitions (Question 6)	15
11.3	Recherche d’états par étiquette (Question 7)	15
11.4	Test de reconnaissance d’un mot (Question 8)	15
11.5	Traitement par lots depuis un fichier <code>.txt</code> (Question 9)	16
12	Difficultés Rencontrées et Solutions	16
13	Conclusion de la Phase 2	16
14	Introduction de la Phase 3	17
15	Détails Algorithmiques	17
15.1	Réindexation des états (méthode d’Offset)	17
15.2	Gestion du non-déterminisme et transitions ϵ	17

16 Code Source Significatif	18
16.1 Concaténation d'automates	18
16.2 Suppression physique des Epsilon	18
17 Organisation et Répartition du Travail	19
18 Conclusion Générale	19

1 Introduction Générale

Dans le cadre du module de Théorie des Langages et Compilation, l'objectif global de ce projet est de développer un programme permettant de remplir une partie de la table des symboles à partir soit d'une expression régulière, soit d'un automate fini décrit sous forme d'un fichier dot. Ce rapport retrace l'évolution de notre projet et se divise en plusieurs parties correspondantes aux différentes phases de développement.

Partie 1 : Lecture et affichage d'un automate

Période de réalisation : 23 Février 2026 - 29 Février 2026

2 Introduction de la Phase 1

Ce premier volet détaille la "Partie 1 : Lecture et affichage d'un automate", première étape de notre travail. Il retrace notre démarche chronologique, de la recherche théorique à l'implémentation finale des structures de données, en passant par la mise en place d'un environnement de travail collaboratif robuste.

3 Recherche Préliminaire, Outils et Étude de Projets Existants

3.1 Concepts Théoriques

D'un point de vue formel, et comme défini dans le support de cours de Théorie des Langages, un automate fini (ou machine à états finis) est un modèle mathématique de calcul. Il est précisément caractérisé par un 5-uplet (Q, A, δ, q_0, F) où :

- Q représente l'ensemble des états (qui est fini dans le cas d'un automate fini) ;
- A désigne l'alphabet de l'entrée ;
- δ est la fonction de transition, définie formellement comme $\delta : Q \times A \rightarrow Q$;
- $q_0 \in Q$ est l'état initial, sachant qu'un automate peut éventuellement posséder plusieurs états initiaux ($q_0 \subseteq Q$) ;
- $F \subseteq Q$ constitue l'ensemble des états d'acceptation (ou états finaux).

En informatique, ces modèles sont fondamentaux dans la conception de compilateurs, l'analyse lexicale, et la vérification de systèmes.

3.2 Format DOT et Écosystème Graphviz

Pour décrire la structure de nos automates, nous avons opté pour le format `.dot`, conformément aux spécifications du projet. Il s'agit d'un langage de description de graphes en texte brut issu de l'écosystème open-source **Graphviz**. Ce format intuitif modélise naturellement les états sous forme de nœuds et les transitions sous forme d'arêtes orientées (*edges*).

3.3 Manipulation Visuelle

Afin de vérifier la validité de notre parsing, il était nécessaire de visualiser graphiquement les automates. Sur environnement Linux, nous avons utilisé l'utilitaire de commande `dot` fourni par Graphviz pour générer des images (PNG ou PDF) à partir de nos fichiers textes. La commande employée était typiquement : `dot -Tpng automate.dot -o automate.png`

Pour faciliter le flux de travail des membres de l'équipe opérant sous environnement Windows, des convertisseurs Graphviz en ligne, tels que *GraphvizOnline*, ont été utilisés comme alternative efficace sans nécessiter d'installation locale complexe.

3.4 Inspiration et Étude de Projets Existants

Avant d'entamer la phase d'implémentation, une recherche a été menée sur des plateformes de partage de code telles que **GitHub**. L'analyse de projets open-source similaires (notamment des parsers de graphes développés en C et des manipulateurs d'expressions régulières) nous a permis d'identifier les meilleures pratiques de l'industrie. Ces recherches nous ont particulièrement inspirés sur la gestion dynamique de la mémoire et les design patterns d'analyse syntaxique pour le traitement de fichiers texte de manière robuste.

4 Environnement de Travail et Choix Techniques

4.1 Le Langage C

Le langage **C** a été retenu pour le développement de ce projet. Ce choix se justifie d'une part par son adéquation naturelle avec les concepts bas niveau de la théorie des langages (développement d'analyseurs lexicaux et syntaxiques). D'autre part, le C offre un contrôle fin sur la gestion de la mémoire via les pointeurs, une caractéristique indispensable pour optimiser la manipulation des tables de symboles et des graphes volumineux.

4.2 Git et Collaboration sur GitHub

Étant une équipe de 5 membres, l'utilisation d'un système de contrôle de version distribué tel que **Git** (hébergé sur GitHub) était impérative. L'intégralité du code source de notre projet ainsi que l'historique de nos contributions sont accessibles sur notre dépôt public : https://github.com/AbdellahBouarguan/projet_theorie_langages.

La collaboration s'est orchestrée autour de la stratégie du *Feature Branching* : chaque développeur travaillait sur une branche isolée pour sa tâche spécifique avant de soumettre une *Pull Request*. La protection de la branche principale (**main**) a été instaurée pour empêcher l'écrasement involontaire du code et s'assurer que seules des implémentations testées y soient fusionnées.

4.3 Standardisation de la Compilation avec CMake

Initialement, la compilation du projet reposait sur un simple **Makefile**. Cependant, une problématique de portabilité s'est rapidement imposée au sein de notre équipe hétérogène (utilisation de Linux, couplée à des systèmes d'exploitation Windows). Les commandes de shell Unix appelées dans le fichier **Make** n'étaient pas reconnues nativement sous Windows.




FIGURE 1 – Structure de notre dépôt public sur GitHub

Default	
Branch	Updated
main	yesterday
Active branches	
Branch	Updated
feature-nafissa-affichageAndLastC...	8 minutes ago
feature-nizar-display	yesterday
feature-ilyass-parser	yesterday
feature-marouane-structures	yesterday

FIGURE 2 – Illustration de notre stratégie de Feature Branching

Pour résoudre ce goulet d'étranglement, nous avons migré vers **CMake**. Cet outil génère un processus de compilation agnostique vis-à-vis du système d'exploitation, créant des **Makefiles** sous Linux et des solutions Visual Studio ou MinGW sous Windows, uniformisant ainsi notre chaîne de build multiplateforme.

5 Organisation et Répartition du Travail

La réussite de cette première phase repose sur une répartition stricte et coordonnée des responsabilités entre les membres de l'équipe :

- **Abdellah** : Chargé de l'initialisation de l'architecture des répertoires et de la configuration de l'infrastructure de base (Git et CMake). Il supervise le bon fonctionnement du projet et la coordination de l'équipe, gère la chaîne de compilation et l'exécution du programme, et assure la rédaction documentaire garantissant la traçabilité des choix techniques.
- **Nizar** : Responsable de la traduction des automates finis vus en cours vers le format DOT à l'aide de l'outil en ligne **GraphvizOnline** (génération des fichiers `data/example1.dot` et `data/example2.dot`). Il a également pris en charge la modélisation mathématique en structures de données logicielles (conception du module `automate.h`) et a contribué au développement du moteur d'affichage (`display.c`).
- **Marouane** : En charge du développement du moteur d'analyse syntaxique permettant la lecture et l'extraction de données depuis les fichiers DOT (`parser.c`). Il a également contribué à la conception de la structure de données (`automate.h`) et a initialisé l'intégration de cet automate au sein du `parser`.
- **Ilyas** : Développeur du module d'affichage console, s'assurant que la machinerie interne soit exposée lisiblement à l'écran (`display.c`). Il a aussi activement participé au développement du module d'analyse syntaxique (`parser.c`).
- **Nafisa** : Responsable de l'intégration globale des modules et conceptrice de l'interface utilisateur interactive (le menu principal dans `main.c`).

6 Conception et Implémentation de la Phase 1

6.1 Structures de données (Question 1 : `automate.h`)

Afin de répondre au premier objectif du cahier des charges de la **Question 1** demandant de proposer des structures de données permettant l'implémentation d'un automate fini, nous avons défini des structures en C capables de stocker les états, les transitions, l'alphabet, ainsi que la nature de chaque état (initial, final).

La structure **Transition** modélise un arc entre deux états, étiqueté par un symbole de l'alphabet :

```
1 // Structure pour une transition
2 typedef struct {
3     int from_etat;
4     int to_etat;
5     char label[MAX_LABEL_LEN];
6 } Transition;
```

Listing 1 – Structure **Transition** (extraite de `automate.h`)

La structure **Automaton** regroupe toutes les informations pertinentes pour définir formellement l'automate (états, transitions, alphabet, booléens pour la nature des états) :


```

1 #define MAX_ETATS 100
2 #define MAX_TRANSITIONS 500
3 #define MAX_ALPHABET 50
4 #define MAX_LABEL_LEN 64
5 // Structure pour l'automate
6 typedef struct {
7     int num_etats;
8     int etats[MAX_ETATS]; // Liste des identifiants (ex: 0, 1, 2)
9     bool is_final[MAX_ETATS]; // Indique si l'état est final
10    bool is_initial[MAX_ETATS]; // Indique si l'état est initial
11
12    int num_transitions;
13    Transition transitions[MAX_TRANSITIONS];
14
15    int num_alphabet;
16    char alphabet[MAX_ALPHABET][MAX_LABEL_LEN];
17 } Automaton;

```

Listing 2 – Structure Automaton (extraite de automate.h)

6.2 Lecture et stockage (Question 2 : Parsing dans parser.c)

Pour la **Question 2**, l'objectif consistait à ajouter une fonction permettant de lire et stocker un automate fini à partir d'un fichier `.dot`. L'un des défis majeurs fut l'extraction fiable des informations pertinentes de ce format texte.

Nous avons implémenté la fonction `load_automaton_from_dot`, qui constitue le cœur de notre analyseur syntaxique (*parser*). Son rôle est de parcourir le fichier texte et de traduire les descriptions graphiques en données exploitables en mémoire. Afin de la rendre robuste et de contourner les spécificités du format DOT, la fonction opère selon les étapes séquentielles suivantes :

1. **Ouverture sécurisée du fichier** : Le fichier est ouvert en mode lecture ("r"). Si le fichier est introuvable ou illisible, le programme signale une erreur dans la console et interrompt le chargement proprement, évitant ainsi une erreur de segmentation.
2. **Filtrage ligne par ligne** : Le fichier est lu ligne après ligne via la fonction `fgets`. Pour optimiser le traitement, le programme ignore les lignes de décoration globale et se concentre exclusivement sur les lignes définissant des relations, identifiables par la présence de la chaîne d'arête `->`.
3. **Détection de l'état initial (Astuce du nœud fantôme)** : Dans les conventions de tracé Graphviz, un état initial est souvent matérialisé par une flèche provenant d'un nœud invisible ou vide (par exemple : `" " -> 0`). Notre algorithme intercepte ce motif vide `" "`, le remplace dynamiquement en mémoire par un identifiant lisible (`"IN"`), ce qui permet à la fonction `sscanf` de l'analyser. L'état pointé par cette flèche voit alors son attribut `is_initial` basculer à `true`.
4. **Détection des états finaux** : De manière similaire, notre code gère une autre convention où un état final pointe vers un nœud d'arrêt (par exemple : `3 -> fin_node`). Si la destination de la flèche commence par les lettres `"fin"`, l'état d'origine est enregistré comme étant un état acceptant (`is_final = true`).
5. **Extraction des transitions régulières et construction de l'alphabet** : Pour les véritables transitions entre deux états de l'automate :

- Le programme isole les identifiants de l'état de départ et de l'état d'arrivée, en prenant soin de nettoyer les éventuels caractères parasites de syntaxe (tels que les crochets d'attributs [ou les points-virgules de fin de ligne ;).
- Il recherche ensuite l'attribut `label=` pour en extraire le symbole de transition, en gérant de manière sécurisée la lecture entre les guillemets.
- Ces informations sont structurées sous forme d'une `Transition` puis ajoutées au tableau `transitions` de notre automate.
- *Gestion de l'alphabet* : Si l'étiquette extraite n'est pas le mot vide (représenté ici par la chaîne "epsilon"), elle est envoyée à la fonction `add_to_alphabet` pour enrichir dynamiquement l'alphabet global de l'automate sans créer de doublons.

6. **Sécurité par défaut (*Fallback initial*)** : Une fois le fichier entièrement lu et re-fermé, le programme effectue une ultime vérification. Si le formatage du fichier DOT ne précisait explicitement aucun état initial, l'algorithme affecte cette propriété par défaut au premier nœud identifié (indice 0), garantissant ainsi que l'automate reste valide et manipulable pour les opérations futures.

```

1 bool load_automaton_from_dot(Automaton *automate, const char *filename)
2 {
3     FILE *file = fopen(filename, "r");
4     if (!file)
5     {
6         printf("Erreur: Impossible d'ouvrir le fichier %s\n", filename);
7         return false;
8     }
9
10    char line[256];
11
12    while (fgets(line, sizeof(line), file))
13    {
14        char *arrow_pos = strstr(line, "->");
15
16        // Nous nous intéressons uniquement aux lignes contenant des
17        // transitions
18        if (arrow_pos)
19        {
20            char from_str[64] = {0};
21            char to_str[64] = {0};
22            char label_str[64] = "epsilon";
23
24            // Solution pour les nœuds avec chaîne vide (ex: "" -> 0)
25            // Remplacer "" par un identifiant temporaire "IN" afin que sscanf
26            // puisse l'analyser comme un seul token
27            char temp_line[256];
28            strcpy(temp_line, line);
29            char *empty_node = strstr(temp_line, "\\\"");
30            if (empty_node && empty_node < (temp_line + (arrow_pos - line)))
31            {
32                empty_node[0] = 'I';
33                empty_node[1] = 'N'; // Transforme "" en IN
34            }
35
36            // Extraire la source et la destination
37            if (sscanf(temp_line, " %s -> %s", from_str, to_str) != 2)
38                continue;
39        }
40    }
41}

```

```

38 // Supprimer les crochets ou points-virgules à la fin de la
    destination
39 char *bracket = strchr(to_str, '[');
40 if (bracket)
41     *bracket = '\0';
42 char *semi = strchr(to_str, ';');
43 if (semi)
44     *semi = '\0';
45
46 // 1. Détection de l'état initial ("IN" -> État)
47 if (strcmp(from_str, "IN") == 0)
48 {
49     int to_id = parse_etat_id(to_str);
50     if (to_id != -1)
51     {
52         int idx = get_or_create_etat_idx(automate, to_id);
53         automate->is_initial[idx] = true;
54     }
55     continue;
56 }
57
58 // 2. Détection de l'état final (État -> "fin*")
59 if (strncmp(to_str, "fin", 3) == 0)
60 {
61     int from_id = parse_etat_id(from_str);
62     if (from_id != -1)
63     {
64         int idx = get_or_create_etat_idx(automate, from_id);
65         automate->is_final[idx] = true;
66     }
67     continue;
68 }
69
70 // 3. Traitement des transitions normales
71 int from_id = parse_etat_id(from_str);
72 int to_id = parse_etat_id(to_str);
73
74 if (from_id != -1 && to_id != -1)
75 {
76     char *label_pos = strstr(line, "label");
77     if (label_pos)
78     {
79         char *quote1 = strchr(label_pos, '"');
80         if (quote1)
81         {
82             char *quote2 = strchr(quote1 + 1, '"');
83             if (quote2)
84             {
85                 strncpy(label_str, quote1 + 1, quote2 - quote1 - 1);
86                 label_str[quote2 - quote1 - 1] = '\0';
87             }
88         }
89         else
90         {
91             sscanf(label_pos, "label=%63[^\t;,\n]", label_str);
92         }
93     }
94 }

```

```

95     int from_idx = get_or_create_etat_idx(automate, from_id);
96     int to_idx = get_or_create_etat_idx(automate, to_id);
97
98     if (automate->num_transitions < MAX_TRANSITIONS)
99     {
100         Transition *t = &automate->transitions[automate->
num_transitions++];
101         t->from_etat = automate->etats[from_idx];
102         t->to_etat = automate->etats[to_idx];
103         strcpy(t->label, label_str);
104
105         if (strcmp(label_str, "epsilon") != 0)
106         {
107             add_to_alphabet(automate, label_str);
108         }
109     }
110 }
111 }
112 }
113 // Par défaut, considérer le premier état (index 0) comme initial
114 // si aucun état initial n'est explicitement défini via "" -> X
115 bool has_initial = false;
116 for (int i = 0; i < automate->num_etats; i++)
117 {
118     if (automate->is_initial[i])
119     {
120         has_initial = true;
121         break;
122     }
123 }
124 if (!has_initial && automate->num_etats > 0)
125 {
126     automate->is_initial[0] = true;
127 }
128
129 fclose(file);
130 return true;
131 }

```

Listing 3 – Logique de la fonction `load_automaton_from_dot` (fichier `parser.c`)

6.3 Moteur d’affichage (Question 3 : `display.c`)

Une fois l’automate chargé, la **Question 3** du cahier des charges exigeait d’ajouter une fonction permettant d’affichage les informations d’un automate passé en paramètre la liste des états, la liste des transitions, l’alphabet, les états finaux, les états initiaux. Ainsi, la fonction `display_automaton` a été développée.

Son rôle est de parcourir la structure en mémoire et d’afficher de façon lisible dans la console :

- La liste de tous les états récupérés.
- La liste restreinte des états initiaux et finaux (états acceptants).
- L’alphabet complet déduit des étiquettes des transitions.
- La liste complète des transitions formatée (ex : $\delta(q_0, a) = q_1$).

6.4 Interface interactive (Question 4 : `main.c`)

Pour répondre à la **Question 4** et orchestrer ces différentes fonctionnalités, nous devons ajouter un menu à notre programme. Ce menu a été intégré au fichier `main.c` et propose les options suivantes de manière cyclique :

1. **Charger un automate** : L'utilisateur saisit le chemin du fichier `.dot`.
2. **Afficher les informations** : Invoque la fonction `display_automaton`.
3. **Quitter** : Libère la mémoire et termine le programme proprement.

7 Difficultés Rencontrées et Solutions

Le développement de cette première itération n'a pas été sans obstacles. Nous soulignons notamment trois problématiques majeures résolues par l'équipe :

1. **Manipulation ardue des chaînes de caractères en C** : L'extraction fiable des labels de transition encadrés par des guillemets dans les fichiers DOT a nécessité des manipulations de pointeurs complexes et une forte vigilance quant aux débordements de tampons (buffers overflow), le C ne possédant pas de regex natives.
2. **Courbe d'apprentissage de Git** : Dans les premiers jours, la synchronisation du travail a été parasitée par des conflits de fusion (*merge conflicts*). Cela a imposé un temps d'adaptation et des sessions de résolution de conflits didactiques entre les membres.
3. **Incompatibilité OS pour la compilation** : La rigidité de notre premier `Makefile` n'a pas survécu à l'environnement Windows d'une partie de l'équipe, paralysant momentanément la compilation avant que nous n'adoptions l'approche *cross-platform* de CMake.
4. **Lecture des chemins de fichiers sous Windows** : Nous avons rencontré un problème lors de la saisie des chemins de fichiers avec la fonction `scanf("%255s", filename)`. Sous Windows, les chemins contiennent souvent des espaces et des antislashs qui faisaient échouer la lecture simple par cette fonction, nécessitant des ajustements pour capturer correctement la chaîne de caractères.

8 Conclusion de la Phase 1

En conclusion pour cette première semaine de développement, les bases techniques et organisationnelles du projet ont été solidement établies. La modélisation mathématique de l'automate fini a été transposée efficacement en structures C opérationnelles. Le système est désormais capable de dialoguer avec des fichiers standards (DOT) et de restituer l'information extraite, validant ainsi la totalité de la Partie 1 et ouvrant la voie à des manipulations plus complexes.

Partie 2 : Manipulation d'un automate

Période de réalisation : 2 Mars 2026 - 8 Mars 2026

9 Introduction de la Phase 2

Cette deuxième partie du projet porte sur la manipulation avancée des automates finis en validant les acquis théoriques du cours. Nous avons étendu notre programme pour inclure la génération de fichiers au format DOT, l'analyse des propriétés du graphe (transitions entrantes et sortantes), et l'évaluation de la reconnaissance de mots (simulation d'AFN). Ce travail a été intégré au menu interactif principal du programme.

10 Répartition du Travail

Tout comme la première phase, la répartition des tâches a été essentielle pour la réussite de cette deuxième étape :

- **Nizar** et **Nafisa** : Ont effectué une recherche initiale exhaustive sur les problématiques soulevées par les **Questions 5 à 9** afin de familiariser l'équipe avec les objectifs à atteindre. Ils se sont chargés d'expliquer les notions théoriques issues du cours du professeur et d'identifier la démarche algorithmique requise pour le traitement de chaque question.
- **Ilyas** : S'est chargé de la réalisation technique de la **Question 5**, concevant et implémentant l'outil interactif de génération de fichiers DOT au sein du module `generate.c`.
- **Abdellah** et **Marouane** : Ont collaboré sur l'implémentation algorithmique de la manipulation avancée des automates et de la simulation de reconnaissance de mots, en couvrant l'intégralité du développement pour les **Questions 6 à 9**.

11 Conception et Implémentation

11.1 Génération d'un fichier DOT (Question 5)

Pour répondre à la **Question 5**, nous avons implémenté la fonction `generate_dot` dans le fichier `generate.c`. Cette fonction permet de créer manuellement un automate de manière interactive depuis la console et de le sauvegarder dans un fichier `.dot`. Elle s'assure de respecter les conventions de nommage et notations du cours. Notamment, elle

utilise un nœud invisible "" pour pointer vers les états initiaux, et crée des arcs vers des états finalX pour représenter graphiquement les états d'acceptation.

```

1   fprintf(f, "%d -> %d [label=\"%s\"];\\n", a->transitions[i].from_etat
2   ,
3       a->transitions[i].to_etat, a->transitions[i].label);
4
5   fprintf(f, "node [shape=point];\\n");
6   for (int i = 0; i < a->num_etats; i++)
7       if (a->is_final[i])
8           fprintf(f, "%d -> final%d;\\n", a->etats[i], a->etats[i]);
9
10  fprintf(f, "\\n");
11  fclose(f);
12  printf("Automate exporté avec succès dans '%s'.\\n", filename);

```

Listing 4 – Extrait de la génération DOT (fichier generate.c)

11.2 Statistiques sur les transitions (Question 6)

La **Question 6** demandait d'identifier l'état possédant le plus grand nombre de transitions entrantes et sortantes. Dans `manipulation.c`, la fonction `afficher_etat_max_transitions` calcule ces degrés pour chaque nœud en parcourant le tableau global des transitions de l'automate. Des compteurs locaux sont maintenus pour chaque état (`in_count` et `out_count`). Le programme détermine ensuite le maximum global et l'affiche à l'utilisateur.

11.3 Recherche d'états par étiquette (Question 7)

Pour la **Question 7**, l'objectif était d'afficher les états ayant au moins une transition sortante étiquetée par un symbole précis (passé en paramètre). La fonction `afficher_etats_transition_label` parcourt les transitions de l'automate et compare l'étiquette demandée avec celle de chaque transition via `strcmp`. Les états correspondants sont extraits et affichés sans doublons, grâce à un tableau de marquage booléen `printed`.

11.4 Test de reconnaissance d'un mot (Question 8)

La vérification de mots (**Question 8**) constitue une partie essentielle. Comme un automate peut être non déterministe (AFN) et comporter des transitions ϵ (epsilon), la simple itération linéaire sur le mot ne suffit pas. Nous avons implémenté un algorithme de recherche en profondeur récursif (backtracking) dans la fonction interne `match_recursive`.

- L'algorithme avance dans le graphe de l'automate en consommant les lettres du mot.
- Les transitions ϵ sont franchies sans consommer de lettre. Pour éviter les boucles infinies de transitions ϵ , nous maintenons un tableau `visited_eps` des états déjà visités lors de l'évaluation du même caractère.
- Si toute la chaîne est consommée et que nous nous trouvons dans un état final (ou qu'un état final est atteignable via des transitions ϵ), le mot est accepté.

La fonction publique `tester_mot` initialise cette recherche à partir de tous les états initiaux. L'interaction avec l'utilisateur (saisie depuis l'invite de commande) est gérée par la méthode `lire_et_tester_mot`.

11.5 Traitement par lots depuis un fichier .txt (Question 9)

Enfin, pour la **Question 9**, la fonction `filtrer_mots_fichier` permet de vérifier automatiquement une série de mots lus depuis un fichier texte (les mots étant séparés par des espaces ou retours à la ligne). Pour chaque mot extrait par `fscanf`, la fonction invoque `tester_mot`. Si l'automate reconnaît le mot, ce dernier est écrit dans un fichier de sortie `MotsAccepter.txt`. À l'issue du traitement, le programme affiche un résumé statistique du nombre total de mots lus et du nombre de mots acceptés.

12 Difficultés Rencontrées et Solutions

Lors de cette deuxième phase de développement, l'équipe a fait face à de nouveaux défis techniques, principalement liés à la manipulation avancée des graphes :

1. **Mise en œuvre du Backtracking avec les transitions ϵ** : L'une des plus grandes difficultés a été la modélisation mathématique du non-déterminisme, en particulier les cycles infinis créés par les transitions epsilon (ϵ). *Solution* : Nous avons introduit un tableau booléen `visited_eps` dans notre algorithme récursif (`match_recursive`) pour mémoriser les états déjà traversés lors de l'évaluation d'une lettre, cassant ainsi les boucles infinies.
2. **Gestion des correspondances exactes de mots** : Lors de la vérification, il était parfois complexe de distinguer la fin d'un mot valide d'une correspondance partielle. *Solution* : La condition d'acceptation a été strictement définie : l'algorithme doit consommer l'intégralité de la chaîne de caractères (`pos == strlen(mot)`) ET se trouver dans un état final (ou pouvoir en atteindre un via epsilon).
3. **Création manuelle d'automates via la console** : La génération d'un fichier DOT valide (**Question 5**) via l'interface console introduisait des risques d'erreurs de saisie utilisateur risquant de corrompre le fichier généré. *Solution* : Le flux d'interaction de `generate.c` a été conçu de manière séquentielle et stricte, forçant d'abord la définition de l'architecture nodale (états normaux, initiaux, finaux) avant de lier les relations (numombre de transitions, états de départ/arrivée et labels).

13 Conclusion de la Phase 2

Les objectifs de la Partie 2 ont été atteints avec succès. Le système modélise fidèlement le comportement d'un AFN grâce à son algorithme de parcours incluant les ϵ -transitions, permettant ainsi de manipuler pleinement l'automate et de tester la reconnaissance de mots. Couplé aux fonctionnalités de parsing de la Phase 1, le programme final est complètement opérationnel et offre une gestion intégrale des automates finis.

Partie 3 : Opérations sur les automates

Période de réalisation : 23 Mars 2026 - 28 Mars 2026

14 Introduction de la Phase 3

Cette troisième phase marque le point culminant de notre moteur d'automates. L'enjeu est de passer de simples automates statiques à des structures dynamiques capables d'être combinées et transformées. Nous avons introduit les opérations de base (concaténation, union) et l'algorithme de **Thompson** pour convertir des expressions régulières en NFAs. Un point critique de cette phase est la gestion des transitions ϵ (epsilon), indispensables pour l'algorithme de Thompson, mais qui nécessitent une suppression rigoureuse (**fermeture-epsilon**) pour simplifier l'analyse et l'affichage final.

15 Détails Algorithmiques

15.1 Réindexation des états (méthode d'Offset)

Lors de la concaténation ou de l'union de deux automates A et B , un problème majeur survient : la collision des identifiants (IDs) d'états. Si A possède un état 0 et B également, la fusion directe corrompt la logique du graphe. *Solution* : Nous avons implémenté une fonction utilitaire `copy_and_offset_states`. Avant d'ajouter B au nouvel automate, nous calculons le plus grand ID présent dans A et l'utilisons comme décalage (*offset*) pour tous les IDs de B . Cette approche garantit une séparation stricte des espaces de noms d'états dans l'automate résultant.

15.2 Gestion du non-déterminisme et transitions ϵ

Deux approches ont été explorées pour gérer les transitions vides (ϵ) :

1. **Backtracking (Test de mots)** : Lors de la simulation, l'algorithme explore récursivement tous les chemins possibles dès qu'il rencontre une transition ϵ , sans consommer de caractère. Bien qu'efficace pour tester ponctuellement, cette méthode devient coûteuse sur de grands graphes.
2. **Suppression d'Epsilon (ϵ -closure)** : Pour "nettoyer" l'automate, nous calculons la fermeture transitive des transitions ϵ via l'algorithme de **Floyd-Warshall**. Pour chaque chemin $q_i \xrightarrow{\epsilon^*} q_j \xrightarrow{a} q_k \xrightarrow{\epsilon^*} q_l$, nous créons une transition directe

$q_i \xrightarrow{a} q_l$. Cette transformation simplifie radicalement l'automate en le ramenant à un AFN sans transitions ϵ .

16 Code Source Significatif

16.1 Concaténation d'automates

La concaténation relie chaque état final de l'automate A aux états initiaux de B par des transitions ϵ .

```

1 Automaton *concatener_automates(const Automaton *a1, const Automaton *a2
  ) {
2     Automaton *res = create_automaton();
3     copy_and_offset_states(res, a1, 0); // Copie de A
4     int offset = get_max_id(a1) + 1;
5     copy_and_offset_states(res, a2, offset); // Copie de B decalée
6
7     for (int i = 0; i < a1->num_etats; i++) {
8         if (a1->is_final[i]) {
9             res->is_final[i] = false; // Transition vers B
10            for (int j = 0; j < a2->num_etats; j++) {
11                if (a2->is_initial[j]) {
12                    add_transition(res, res->etats[i], res->etats[a1->num_etats+j
13                        ], "epsilon");
14                }
15            }
16        }
17    }
18    return res;
19 }
```

Listing 5 – Logique de concaténation (operations.c)

16.2 Suppression physique des Epsilon

Cette fonction utilise une matrice d'adjacence booléenne pour calculer la fermeture.

```

1 void supprimer_epsilon_transitions(Automaton *a) {
2     bool closure[MAX_ETATS][MAX_ETATS];
3     // ... Calcul de la fermeture via Floyd-Warshall ...
4     for (int k = 0; k < a->num_etats; k++)
5         for (int i = 0; i < a->num_etats; i++)
6             for (int j = 0; j < a->num_etats; j++)
7                 if (closure[i][k] && closure[k][j]) closure[i][j] = true;
8
9     // Heritage des etats finaux
10    for (int i = 0; i < a->num_etats; i++)
11        for (int j = 0; j < a->num_etats; j++)
12            if (closure[i][j] && a->is_final[j]) a->is_final[i] = true;
13
14    // Generation des transitions directes sans epsilon
15    // ... (Code de generation de new_transitions) ...
16    a->num_transitions = new_count;
17 }
```

Listing 6 – Suppression des transitions epsilon (fermeture transitive)

17 Organisation et Répartition du Travail

Pour cette phase finale, l'équipe a adopté une structure de développement en couches :

- **Abdellah** : Architecture des opérations complexes et implémentation de l'algorithme de Thompson (regex vers NFA) et Shunting-Yard.
- **Nizar** : Conception de la logique de réindexation (*offsetting*) et des outils de fusion.
- **Marouane** et **Ilyass** : Développement et optimisation du module de fermeture-epsilon et de la structure de backtracking.
- **Nafisa** : Maintenance globale, tests d'intégration et mise à jour de l'interface utilisateur pour inclure les nouvelles opérations.

18 Conclusion Générale

Ce projet nous a permis de concrétiser les concepts abstraits de la théorie des langages en un outil logiciel robuste et polyvalent. De la simple lecture d'un fichier DOT à la transformation complexe d'expressions régulières en automates optimisés, nous avons couvert l'intégralité du pipeline de traitement. Cette expérience a renforcé nos compétences en programmation système (C), en gestion de versions (Git) et en travail d'équipe collaboratif.